


Treinar um modelo com AUC de 0,866 foi a parte fácil.

O difícil foi responder: dá para usar isso para aprovar crédito, e de forma justa?

4 hipóteses, uma análise de viés e o monitoramento em produção. O que cada etapa revelou →

O QUE MAIS PESA NO RISCO

Comportamento pesa mais que perfil.



Uso do limite e histórico de atrasos dominam o modelo.
Renda, dependentes e imóveis ficam bem atrás.

H1 · USO DO ROTATIVO

CONFIRMADA

**Quanto mais perto do limite,
maior o risco.**

~0%

de uso do limite: o risco cai

~40%

a variável passa a pesar contra o cliente

~100%


limite estourado: o risco dispara

Detalhe técnico: a correlação de Pearson (0,05) escondia a relação por causa de outliers extremos. Com Spearman: 0,88.

H2 · DÍVIDA/RENDA VS. IDADE

CONTRARIADA

Minha hipótese estava errada: idade pesou 1,6x mais que dívida/renda.




Em crédito, isso é um alerta de viés etário. A análise de viés confirmou: veja a página 7.

H3 · THRESHOLD DE APROVAÇÃO

CONFIRMADA

O corte é decisão de negócio, não um 0,5 padrão.




Com corte em 0,45: inadimplência cai ~74%, mantendo 73% dos pedidos aprovados.

Na mesma aprovação, uma regressão logística deixaria a carteira com 3,08%.

H4 · IMPACTO FINANCEIRO

CONFIRMADA

O modelo erra muito e mesmo assim se paga.




Só 1 em cada 5 recusados era mau pagador. Mas um calote custa ~10x a margem de um bom cliente.

Ponto de equilíbrio: o modelo se paga enquanto um calote custar mais de 4x essa margem. Não depende dos valores simulados.

VIÉS POR IDADE

Um bom pagador jovem é recusado 5,4x mais que um de 60+.

Bons pagadores negados pelo modelo, por faixa etária



Parte é risco real: 12% de inadimplência nos jovens contra 2,8% acima de 60.


Mas zerar a diferença é matematicamente impossível sem abrir mão de outro critério de justiça. É decisão de negócio, jurídico e compliance, não só técnica.

MONITORAMENTO EM PRODUÇÃO

O monitor não alarma à toa, e alarma quando precisa.

11/11

features estáveis no lote real de 101 mil clientes (data drift, PSI e KS)



Concept drift simulado: sem alerta sem mudança; alerta a partir de 25% de intensidade.

STACK E PRÓXIMOS PASSOS

Do CSV ao monitoramento

Databricks · PySpark · Delta · Unity Catalog · MLflow ·
XGBoost · SHAP · pytest

Próximos passos

- Medir o trade-off de um modelo sem a variável idade
- Critério de justiça definido com risco e compliance
- Score calibrado em produção para precificar juros

Base pública: Give Me Some Credit (Kaggle)

Repositório no link do post